

BuildLens AI MVP2 구현 계획서

A6000 48GB 단일 GPU 기준 - 소규모 상업 리모델링 현장어 도면-현장 불일치 탐지, punch list, RFI, change order evidence 자동화

1. MVP2에 제롬 범에

MVP2에 목표는 AI가 현장 결함을 체크 판정하는 것이 아니라, 현장 PM이 검토할 수 있는 '증빙 있는 어심 이슈'를 빠르게 생산하는 것이다. 따라서 모델 출력은 항상 confidence, 근거 문서, 현장 이미지 crop, 도면 책료, 사람이 수정한 체크 상태를 함께 가진다.

구분	MVP1	MVP2
입력	PDF 도면 1세트, 현장 사진	PDF 도면/스펙, 현장 사진/영상, 음성 메모, 제롬 submittal
핵심 처리	도면 텍스트 추출, 사진 기반 이슈 후보 생성	도면 엔티티 추출, RAG, 영상 keyframe, 명면도 민, RFI/CO 초안
출력	punch list 초안 PDF/CSV	이슈 카드, 도면 overlay, RFI draft, change order evidence report
검증 기준	현장 담당자가 수동으로 70% 이상 유용하다고 판단	상에 20개 이슈 중 8개 이상 실제 조치 필요 또는 확인 필요

기능 원칙

- 도면-현장 비교는 확정 판정이 아니라 issue candidate 생성으로 설계한다.
- 모든 AI 결과에는 evidence chain을 보인다: sheet, spec clause, image crop, frame timestamp, model run id.
- 소규모 현장 사용성을 위해 입력은 스마트폰과 PDF 중심으로 제한한다. BIM, 360 카메라, 라이다는 MVP2 필수 조건이 아니다.
- 대형 플랫폼과 경쟁하지 않고 Procore/Bluebeam/Fieldwire에 첨부 가능한 리포트와 API export를 제공한다.

2. 전체 시스템 아키텍처

계층	구성	역할
Frontend	Next.js 또는 React SPA, Cloudflare Pages	프로젝트 생성, 파일 업로드, 이슈 검토, 도면 overlay, 리포트 다운로드
Edge Gateway	Cloudflare Worker	JWT 검증, presigned upload, rate limit, queue publish, KAIST/Render routing
Core API	FastAPI on Render 또는 KAIST Docker	프로젝트/문서/이슈 API, job state, 권한, 결제/사용량
Async Worker	FastAPI worker 또는 Celery/RQ	PDF 마싱, keyframe 추출, embedding, inference orchestration
Storage	Cloudflare R2	원본 PDF/영상, frame, crop, overlay, report, model artifact 저장
DB	PostgreSQL + pgvector	프로젝트 메타데이터, 도면 엔티티, chunk embedding, 이슈, audit log
GPU Server	KAIST A6000 48GB, SGLang/VLLM	VLM 추론, OCR/ASR, detector inference, batch job 처리
Fallback	Render worker + 액부 GPU 또는 Gemini 2.5 API	KAIST 서버 중단 시 queue 기반 비동기 처리

KAIST GPU 서버는 액부에 직접 노출하지 않는다. Cloudflare Tunnel을 통해 model-gateway만 공개하고, API 서버는 내부 service token으로만 GPU 서버를 호출한다. 사용자가 업로드한 파일은 R2에 저장하고, GPU 서버에는 작업 단에 presigned URL만 전달한다.

3. 입력과 출력 사양

입력

입력	형식	처리 방식	MVP2 필수성
도면 세트	PDF, 150~400dpi raster/vector 혼합	PyMuPDF rasterize, OCR, sheet classifier, plan entity detector	필수
스펙/시방서	PDF/DOCX/TXT	section chunking, requirement extraction, RAG index	권장
현장 사진	JPG/PNG/HEIC	EXIF 제거/보존 선택, object detection, VLM observation	필수
현장 영상	MP4/MOV	ffmpeg keyframe, blur filter, frame clustering, representative frame 추론	MVP2 필수
음성 메모	M4A/WAV/MP3	ASR, room/action/entity tagging, issue context로 연결	MVP2 필수
제출 submittal	PDF/CSV	제출명, 모델명, 색상, 치수, 설치 조건 추출	선택

출력

출력	형태	사용 목적
Issue Card	JSON + UI 카드	현장 PM이 승인/반려/수정하는 체크 단계
Plan Overlay	sheet 재료 기반 pins/regions	도면 어디에서 발생한 문제인지 확인
Punch List	PDF/CSV/XLSX	하도급사 전달, 해이록 첨부
RFI Draft	Markdown/PDF	설계자/발주처 질의 초안
Change Order Evidence	PDF report	추가비 청구 또는 일정 지연 증빙
Model Audit Log	DB record	추론 모델, prompt, 입력 hash, confidence 추적

```
{
  "issue_id": "iss_2026_00041",
  "project_id": "prj_tenant_improvement_001",
  "issue_type": "missing_item | location_mismatch | spec_mismatch | unverified | potential_change_order",
  "discipline": "electrical | mechanical | plumbing | architectural | fire_safety",
  "room": "Conference Room 203",
  "requirement": {"source": "A-201", "text": "Install two duplex outlets on north wall"},
  "observation": {"media_id": "vid_12", "frame_ts": 83.2, "text": "Only one outlet is visible"},
  "plan_location": {"sheet_id": "A-201", "x": 0.438, "y": 0.612, "bbox": [0.41,0.59,0.47,0.64]},
  "evidence": ["crop://frame_83_2_outlet.jpg", "chunk://spec_2627_13", "entity://A201_outlet_002"],
  "confidence": 0.74,
  "recommended_action": "Verify installed outlet count before drywall closeout",
  "rfi_draft": "Please confirm whether two duplex outlets are required on the north wall of Conference Room 203."
}
```

4. A6000 48GB 기준 모델 스택

A6000 1장 기준에서는 실시간 멀티유저 추론보다 비동기 batch 처리에 맞춘다. 핵심 전략은 20B 이상 VLM을 4bit/AWQ/FP8로 운용하고, 반복 작업은 작은 detector와 embedding 모델로 내리는 것이다.

모델	권장 모델	A6000 운용 방식	역할
Main VLM	Qwen3-VL-32B-Instruct 4bit/AWQ	batch=1, image resize, structured JSON output, SGLang/vLLM	현장 사진/도면 crop 설명, 누락/보입치 후보 생성
Text Reasoner	Qwen3.6-35B-A3B-FP8 또는 동급 30B+ MoE	VLM과 동시 상주가 어려우면 job별 swap 또는 별도 process	RFI 초안, spec reasoning, report narrative

Embedding	Qwen3-Embedding 계열 또는 BGE-M3	CPU 가능, 대량 index는 GPU batch	도면/스펙/RFI/이슈 chunk 검색
Reranker	Qwen3-Reranker 계열	상여 50 chunk를 5~10개로 압축	RAG hallucination 감소
OCR	HunYuanOCR 또는 PaddleOCR fallback	PDF crop batch 처리	시방서/도면 note/table/room label 추출
ASR	Qwen3-ASR 또는 Whisper large-v3 fallback	음성 메모 batch transcription	현장 구두 설명을 room/context와 연결
Detector	YOLO11/YOLOv12 custom + Grounding DINO	작은 모델은 상시 로드 가능	콘센트, 조명, diffuser, door hardware 등 검출
Segmentation	SAM 계열	필요할 때 crop 단계 호출	객체 mask, 증빙 crop, overlay 생성

메모리 운영 원칙

- Qwen3-VL-32B는 4bit/AWQ로 상주시켜 VLM job을 처리한다. FP16 상주는 A6000 48GB에서 안정성이 낮다.
- Qwen3.6-35B-A3B-FP8은 text reasoning 전용으로 별도 profile에서 실행한다. 동시에 두 대형 모델을 상주시킬 필요는 없다.
- VLM 입력은 엔본 전체가 아니라 sheet crop, room crop, representative frame으로 줄인다.
- 현장 영상은 모든 frame을 VLM에 넣지 않는다. 1~2fps 추출, blur 제거, CLIP/embedding clustering 후 대표 frame만 VLM에 보낸다.
- A6000 서버는 online API가 아니라 async inference worker로 설계한다. 사용자는 job progress를 보고 결과를 받는다.

5. 기능별 구현 상세

5.1 프로젝트 생성과 파일 업로드

항목	구현
사용자 플로우	프로젝트 생성 - 공종 선택 - 도면 업로드 - 현장 미디어 업로드 - 분석 시작 - 이슈 검토
백엔드	POST /projects, POST /documents/presign, POST /media/presign, POST /jobs/analyze
저장	R2 path: org/{org_id}/project/{project_id}/raw/{doc_id}; DB에는 hash, mime, size, upload status
검증	파일 hash 중복 제거, PDF page count 제한, 영상 길이 제한, virus scan hook 자리 확보
결과	job_id 반환, UI는 WebSocket/SSE 또는 polling으로 progress 표시

5.2 도면 인텔리전스

도면 분석은 VLM 하나에 맡기지 않는다. PDF 구조 파싱, OCR, layout, object detector, VLM 검증을 순차적으로 사용한다. MVP2에서 필요한 것은 완벽한 CAD 복원이 아니라 '비교 가능한 requirement graph'를 만드는 것이다.

단계	입력	처리	출력
Sheet classification	PDF page image + title block	OCR + rule + VLM 확인	A-201 floor plan, E-101 electrical, M-201 mechanical 등
Scale/room parsing	plan crop	room label OCR, door/window/wall 후보 검출	room polygon 후보, room name
Symbol detection	electrical/mechanical/plumbing sheet	YOLO custom detector + symbol dictionary	outlet/switch/light/diffuser/sink/toilet 등 entity
Requirement extraction	note/table/spec reference	OCR text chunk + LLM schema extraction	install/verify/count/location/spec requirement
Spatial normalization	sheet image coordinates	bbox to normalized coordinates	x,y,bbox, sheet_id, room_id

```
{
  "entity_id": "ent_A201_outlet_002",
  "sheet_id": "A-201",
  "entity_type": "duplex_outlet",
  "room": "Conference Room 203",
  "bbox": [0.414, 0.602, 0.438, 0.625],
  "source": "detector:v0.3 + vlm_verify:qwen3-vl-32b",
  "confidence": 0.81,
  "linked_requirement_ids": ["req_E101_0007"]
}
```

5.3 스펙/RAG 구축

단계	구현 상세
Parsing	PDF/DOCX/TXT 를 text block, table, heading 으로 분해. section number, page, bounding box 를 보존한다.
Chunking	300~700 token 단에. section boundary 를 넘지 않게 하고, table 은 row 단에 JSON 으로 보존한다.
Metadata	project_id, document_id, spec_section, discipline, page, bbox, revision, effective_date 를 chunk metadata 에 저장한다.
Embedding	Qwen3-Embedding 계열 또는 BGE-M3 로 chunk embedding. pgvector HNSW index 를 사용한다.
Hybrid search	사용자 질문/이슈 후보 생성 시 BM25 + vector + metadata filter 를 병합한다.
Rerank	상여 50개 chunk 를 reranker 로 5~10개로 압축 후 VLM/LLM 에 전달한다.
Citation	모든 답변은 chunk_id 와 page 를 포함한다. citation 없는 답변은 UI에서 낮은 신뢰도로 표시한다.

```
{
  "rag_query": "required outlet count north wall conference room 203",
  "filters": {"project_id": "prj_001", "discipline": ["electrical"], "sheet_id": ["E-101", "A-201"]},
  "retrieval": {"bm25_top_k": 50, "vector_top_k": 50, "rerank_top_k": 8},
  "returned_context": ["chunk_E101_0042", "chunk_spec_2627_0013", "entity_A201_outlet_002"]
}
```

5.4 현장 사진/영상/음성 분석

입력	처리	출력
사진	orientation normalize, blur/brightness score, object detector, VLM description	observations, object boxes, issue candidates
영상	ffmpeg 1~2fps 추출, shot boundary, blur 제거, frame embedding clustering	representative frames, timestamp evidence
음성	ASR, room/entity/action extraction, media timestamp alignment	voice_context: room, issue hint, worker note
사용자 태그	현장 작업자가 room/floor/discipline 을 선택	RAG filter 와 matching 정확도 상승

MVP2에서 사용자가 현장 영상을 찍는 방식은 제한한다. 예: 방 입구에서 방 이름을 말하고 360도 천천히 촬영, 문제 의심 지점에서 2초 정지. 이 제약을 제품 UX에 넣으면 모델 성능보다 더 큰 정확도 개선이 나온다.

5.5 도면-현장 매칭 엔진

매칭 기준	구현
Room matching	음성/사진 태그, room label OCR, VLM room description 을 결합해 room_id 후보를 만든다.
Entity matching	도면 entity type 과 현장 object detector type 을 매칭한다. 예: duplex_outlet - outlet_visible.
Count matching	도면 요구 개수와 현장 객체 개수를 비교하데, 시야 밖 가능성을 unverified 로 분리한다.

Location matching	현장 사진의 벽 방향/door/window cue를 이용해 north/east/south/west 후보를 추정한다.
Spec matching	제품명/색상/치수/설치 높이 등은 spec RAG와 연결해 mismatch 후보를 만든다.
Confidence	vision confidence, retrieval confidence, room confidence, contradiction score를 가중 평균한다.

중요한 설계는 'missing'과 'unverified'를 분리하는 것이다. 사진에 안 보인다고 누락으로 단정하면 현장 실패를 잃는다. 따라서 MVP2의 기본 라벨은 missing_item, location_mismatch, spec_mismatch, unverified, potential_change_order로 제한한다.

5.6 이슈 생성과 사람 검토 UI

UI 기능	세부 동작
Issue inbox	confidence, 공중, room, severity, due date로 정렬/필터
Evidence viewer	왼쪽 도면 crop, 오른쪽 현장 crop/frame, 아래 spec chunk citation
Action buttons	Approve, Reject, Need more evidence, Convert to RFI, Convert to punch item
Edit controls	room, severity, assignee, description, due date, subcontractor 수정
Learning signal	승인/반려/수정 내용을 model_feedback 테이블에 저장해 active learning에 사용

5.7 RFI와 Change Order Evidence

출력	내용
RFI Draft	집문, 배경, 관련 도면/스펙, 현장 사진, 요청 결정사항, 희망 해신일
Punch List	예치, 공중, 담당사, 문제, 증빙, 우선순위에, 마감일
CO Evidence Report	변경 연인, 도면/스펙 기준, 현장 객측, 비용/일정 영향 입력란, 첨부 증빙
Export	PDF, CSV, XLSX, Procore/Fieldwire 첨부용 zip

6. 학습 데이터와 학습 전략

MVP2는 대형 VLM 자체를 무리하게 full fine-tuning하지 않는다. 초기 경쟁력은 데이터 마이트라인, detector fine-tuning, RAG grounding, human feedback loop에서 만든다. 대형 VLM은 구조화 출력 안정화용 QLoRA 정도만 선택적으로 적용한다.

데이터	용도	학습 방식
CubiCasa5K	floor plan room/wall/opening 기본 인식	공개 dataset으로 detector pretrain
Structured3D	room layout, synthetic plan/scene alignment	도면-공간 매칭 pretrain
DocLayNet/PubLayNet	PDF layout/table/title block 인식	document layout detector pretrain
현장 pilot 데이터	상업 리모델링 객체/이슈	마일렛 5~10개 현장에서 2,000~5,000 frame 확보
한성 도면	symbol/count/location 테스트	CAD block씩 공개 symbol을 조한해 자동 라벨 생성
사람 검토 로그	false positive/negative 개선	approve/reject/edit를 feedback dataset으로 누적

학습 단계

단계	무엇을 학습	방법	성공 기준
Stage 0	학습 없음	base VLM + RAG + prompt + rules	마일렛 3건에서 유용 이슈 후보 생성

Stage 1	도면 symbol detector	YOLO custom fine-tune, synthetic + CubiCasa/Structured3D	outlet/light/door/window mAP@0.5 0.75+
Stage 2	현장 object detector	pilot frame labeling, Grounding DINO/SAM pseudo-label, human cleanup	핵심 10개 객체 mAP@0.5 0.70+
Stage 3	이슈 classifier	approved/rejected issue card 기반 XGBoost/lightweight classifier	상업 20개 precision 0.55+
Stage 4	VLM structured output	Qwen3-VL-32B QLoRA, 1,000~3,000 instruction examples	JSON validity 98%+, hallucinated citation 5%-

라벨링 스키마

라벨	예시
plan_entity	duplex_outlet, data_port, switch, ceiling_light, diffuser, sink, toilet, door, window, cabinet
site_object	installed_outlet, visible_switch, missing_cover_plate, light_fixture, duct_diffuser, sprinkler_head
issue_type	missing_item, location_mismatch, count_mismatch, spec_mismatch, unverified, potential_change_order
severity	blocker, major, minor, informational
feedback	approved, rejected_false_positive, merged_duplicate, needs_more_evidence, edited_by_user

7. 백엔드 설계

서비스 구성

서비스	기술	책임
api-server	FastAPI, SQLAlchemy, Pydantic v2	REST API, auth, RBAC, project/issue/report CRUD
ingestion-worker	Python worker	PDF rasterize, OCR, metadata extraction, thumbnail 생성
media-worker	ffmpeg, OpenCV	video frame extraction, blur score, frame clustering
rag-worker	embedding model, pgvector	chunking, embedding, hybrid retrieval index
inference-orchestrator	Python async worker	GPU job batching, retry, timeout, model profile 선택
model-gateway	FastAPI on GPU server	SGLang/vLLM OpenAI-compatible endpoint proxy
report-worker	ReportLab/HTML-to-PDF	punch list, RFI, CO evidence report 생성

핵심 DB 테이블

테이블	주요 컬럼
organizations/users/memberships	org_id, user_id, role, billing_status
projects	project_id, org_id, name, address, project_type, status
documents	doc_id, project_id, type, r2_key, hash, revision, parsed_status
sheets	sheet_id, doc_id, sheet_number, discipline, page_no, image_key
plan_entities	entity_id, sheet_id, type, room_id, bbox, confidence, source
spec_chunks	chunk_id, doc_id, text, metadata, embedding vector, page, bbox

site_media/frames	media_id, frame_id, timestamp, r2_key, blur_score, room_hint
observations	observation_id, media_id, object_type, bbox, text, confidence
issues	issue_id, project_id, type, severity, room, status, confidence
issue_evidence	issue_id, evidence_type, ref_id, r2_key, page, bbox, frame_ts
jobs/model_runs	job_id, run_id, model_name, prompt_hash, input_hash, status, latency, cost_estimate

Job state machine

```
{
  "states": ["queued", "ingesting", "indexing", "extracting_frames", "detecting", "reasoning", "review_ready", "failed"],
  "retry_policy": {"max_retries": 3, "backoff": "exponential", "dead_letter_queue": true},
  "idempotency": "job input hash + project revision",
  "progress_events": ["sheet_parsed", "chunk_indexed", "frame_selected", "issue_generated", "report_ready"]
}
```

API 초안

Endpoint	설명
POST /v1/projects	프로젝트 생성
POST /v1/uploads/presign	R2 presigned URL 발급
POST /v1/projects/{id}/analyze	분석 job 생성
GET /v1/jobs/{id}	job 상태 조회
GET /v1/projects/{id}/issues	이슈 목록
PATCH /v1/issues/{id}	승인/반려/수정
POST /v1/issues/{id}/rfi	RFI 초안 생성
POST /v1/projects/{id}/reports	punch/CO 리포트 생성
GET /v1/projects/{id}/plan-overlay	도면 pins/regions 조회

8. 배포 설계

환경	구성	목적
KAIST GPU	Docker Compose: model-gateway, sglang/vllm, detector service, worker	A6000 기반 추론
Cloudflare	Pages, Workers, R2, Queues, Tunnel, WAF	frontend, edge auth, object storage, private GPU 연결
Render	FastAPI web service, background worker, Postgres, Redis-compatible KV	GPU에 분리된 안정적 SaaS backend
Fallback GPU	RunPod/Lambda/Modal 중 하나	KAIST 접결/다운타임 시 queue drain
Fallback API	Gemini 2.5 Pro/Flash 등	초기 demo에 긴급 분석 처리

Render는 GPU 서버가 아니다. Render는 고객-facing backend와 worker를 안정적으로 운영하는 계층이다. 무거운 추론은 KAIST A6000 또는 예부 GPU fallback으로 보낸다. Cloudflare Worker는 파일 업로드와 queue publish, Cloudflare Tunnel은 KAIST 서버를 private inference endpoint로 연결하는 역할을 맡는다.

운영 정책

- 원본 영상은 R2에 저장하고 GPU 서버 로컬에는 job 처리 중 임시 파일만 둔다.
- 모든 model run은 input hash와 output hash를 저장해 재현 가능성을 확보한다.
- 고객별 동시 job 수를 제한한다. 초기 free/pilot은 1개, paid team은 3개로 제한한다.

- 실패한 job은 dead letter queue로 보내고, UI에는 실패 단계와 재시도 버튼을 보여준다.
- 비용 복제 방식을 예해 영상 길이, page 수, frame 수, VLM call 수에 hard limit를 둔다.

9. MVP2 개발 로드맵

주차	목표	완료 기준
1~2	업로드/프로젝트/R2/DB/job skeleton	PDF, 사진, 영상 업로드와 job 상태 조회 가능
3~4	PDF 도면 ingest + OCR + sheet classification	A/E/M/P sheet 구분, title block/page metadata 저장
5~6	RAG v1 + spec requirement extraction	질문에 page/chunk citation 포함 답변 생성
7~8	현장 media pipeline + VLM observation	영상에서 대표 frame 추출, observation JSON 생성
9~10	도면-현장 matching + issue card	issue inbox와 evidence viewer 동작
11	RFI/punch/CO report 생성	PDF/CSV export 가능
12	마일렛 데이터 3건 end-to-end	한 프로젝트당 상에 20개 이슈 후보와 리포트 생성

10. 성능 평가와 합격 기준

영역	지표	MVP2 합격 기준
Ingestion	PDF page parse success	95%+
RAG	citation attached answer ratio	95%+
VLM output	valid JSON ratio	98%+
Issue quality	top-20 precision	40%+ 마일렛, 55%+ 2차 마일렛
False positive	즉시 반려율	60% 이하에서 시작, feedback 후 40% 이하
Latency	20 page PDF + 3분 영상	30분 이내 비동기 완료
Cost	A6000 local inference marginal cost	고객당 월 \$50 이하 infra 목표
Business	paid pilot conversion	무료 마일렛 10건 중 유료 2건 이상

정책도 목표를 처음부터 90%로 잡지 않는다. 현장에서는 AI가 놓친 것보다 AI가 증빙과 함께 찾아준 후보가 실제 업무 시간을 줄이는지가 중요하다. 따라서 top-k precision, review time reduction, RFI 작성 시간 단축을 핵심 지표로 삼는다.

11. 리스크와 대응

리스크	대응
도면 형식 다양성	초기 ICP를 tenant improvement floor/electrical plan으로 제한하고 sheet classifier부터 강화
현장 사진어 시야 밖 문제	missing과 unverified 분리, 촬영 가이드 UX 제공
VLM hallucination	RAG citation mandatory, no-citation low confidence, human approval gate
A6000 메모리 한계	4bit/AWQ, batch=1, model profile 분리, frame selection으로 VLM call 축소
고객 데이터 보안	R2 private bucket, signed URL, Cloudflare Tunnel, per-org RBAC, audit log
경쟁사 모방	소규모 상업 리모델링 데이터셋과 issue feedback loop를 빠르게 축적
초기 판매 난이도	SaaS 영업 구독보다 project evidence report 단건 판매로 시작

12. 첫 마일렛 운영 방식

- 마일렛 대상: Bay Area 또는 KAIST 네트워크 기반 소규모 상업 리모델링/인테리어 프로젝트 3~5건.
- 고객에게 요구할 입력: PDF 도면, 현장 walkthrough 영상 1~3개, 주요 방 사진 30~100장, 음성 데모.
- BuildLens가 제공할 결과: 상에 이슈 후보 20개, 도면 pin overlay, punch list CSV/PDF, RFI 3~5개 초안.
- 가격 검증: 첫 3건은 무료 또는 \$299, 이후 \$499~\$1,500/project evidence report로 전환.
- 학습 데이터 확보: 고객 동의 하에 crop/label/feedback만 익명화 저장. 엔본 도면/영상은 계약 종료 후 삭제 옵션 제공.

13. 참고 자료

분류	자료
GPU	NVIDIA RTX A6000 공식 사양: 48GB VRAM
모델	Qwen3-VL, Qwen3.6, Qwen3-Embedding/Reranker, Qwen3-ASR 공개 자료 및 모델 카드
Serving	SGLang/vLLM OpenAI-compatible serving 문서
데이터	CubiCasa5K, Structured3D, DocLayNet, PubLayNet, Grounding DINO, SAM 계열 자료
Backend	Cloudflare R2/Queues/Tunnel, Render FastAPI/background worker, pgvector 문서
시장	미국 비주거 건설 지출, construction management software 시장 규모 자료

주어: 실제 구현 직전에는 각 모델어 license, commercial use, VRAM 실측, serving framework 지연 상태를 다시 확인해야 한다. 특히 Qwen3.6 계열은 vision 모델이 아니라면 text reasoning/RAG report 전용으로만 사용한다.